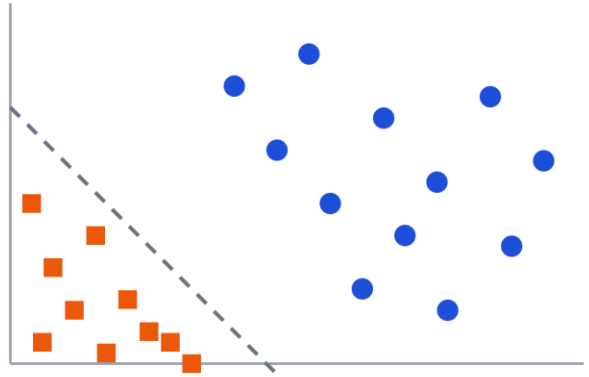
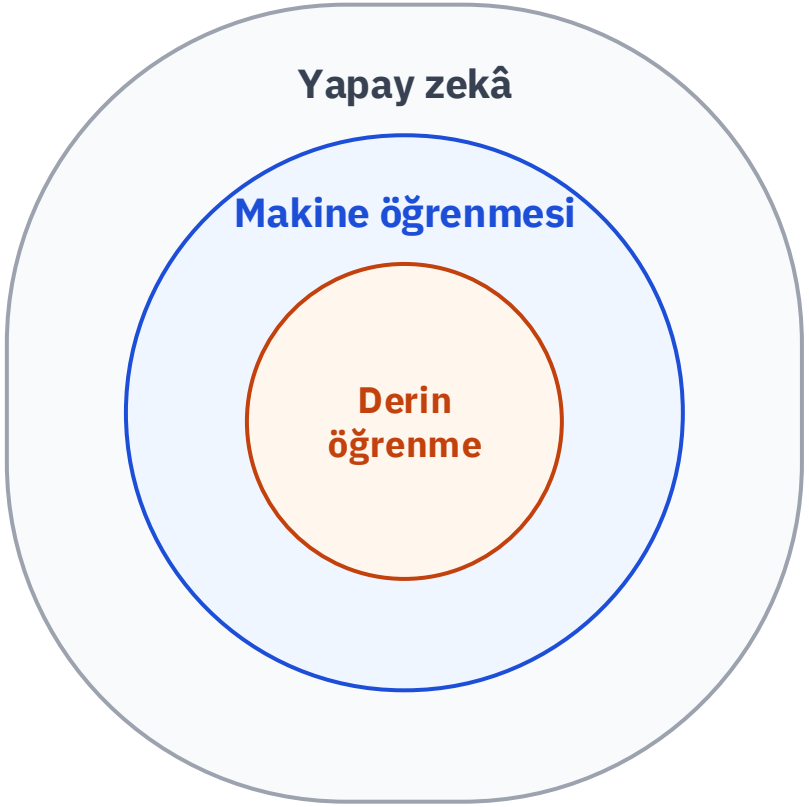
Makine Öğrenmesi

Temel kavramlar, yöntemler ve değerlendirme ölçütleri



TANIMLAR

Yapay zekâ, makine öğrenmesi ve derin öğrenme



Yapay zekâ

İnsan zekâsı gerektiren işleri yapabilen sistemlerin genel adı.

Makine öğrenmesi

Kuralları elle yazmak yerine örnek verilerden öğrenen yöntemler. Örnek: e-posta spam filtresi.

Derin öğrenme

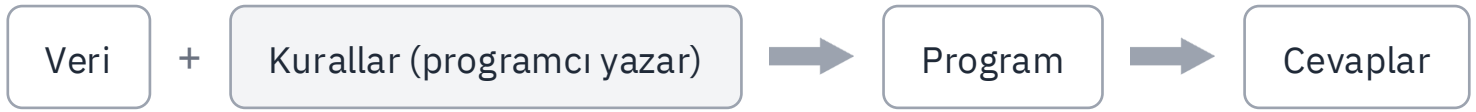
Çok katmanlı yapay sinir ağlarıyla öğrenme. Örnek: yüz tanıma, sohbet robotları.

TANIMLAR

Makine öğrenmesi nedir?

Bilgisayarın, açıkça programlanmadan, örnek verilerdeki örüntüleri bularak bir görevi yapmayı öğrenmesidir. Öğrenmenin sonunda elde edilen yapıya **model** denir.

Geleneksel programlama



Makine öğrenmesi



Örnek: Spam filtresi için "içinde 'bedava' geçiyorsa spam" kuralını yazmak yerine, spam ya da normal diye işaretlenmiş 10.000 e-posta verilir; model ayırt edici ipuçlarını kendisi bulur.

TANIMLAR

Günlük hayatta makine öğrenmesi

Uygulama	Girdi (özellikler)	Çıktı	Öğrenme türü
Spam filtresi	Metin, gönderen, bağlantılar	Spam / normal	Gözetimli · sınıflandırma
Ev fiyatı tahmini	Metrekare, oda sayısı, konum	Fiyat (TL)	Gözetimli · regresyon
Hastalık riski	Yaş, tansiyon, kan değerleri	Risk var / yok	Gözetimli · sınıflandırma
Satış tahmini	Geçmiş satışlar, mevsim, fiyat	Gelecek ay satış adedi	Gözetimli · regresyon
Müşteri gruplama	Harcama tutarı, alışveriş sıklığı	Müşteri grupları	Gözetimsiz · kümeleme
Oyun oynayan program	Oyunun o anki durumu	Bir sonraki hamle	Pekiştirmeli öğrenme

VERİ

Veri seti: örnek, özellik ve etiket

Özellikler (X): modelin girdisi				Etiket (y)
Çanak uz.	**Çanak gen.**	**Taç uz.**	**Taç gen.**	**Tür**
5,1	3,5	1,4	0,2	setosa
7,0	3,2	4,7	1,4	versicolor
6,3	3,3	6,0	2,5	virginica
4,9	3,0	1,4	0,2	setosa
5,9	3,0	5,1	1,8	virginica

Iris veri seti (150 çiçek, 4 ölçüm, 3 tür). Ölçüler santimetre.

Örnek (satır)

Tek bir gözlem: bir çiçek, bir hasta, bir ev.

Özellik (sütun)

Örneği tanımlayan ölçülebilir bilgi. İngilizcesi *feature*.

Etiket (hedef)

Tahmin edilmek istenen doğru cevap. İngilizcesi *label*.

VERİ

Etiketli veri ve etiketsiz veri

Etiketli veri

Metrekare	Oda	Yaş	Fiyat
90	2	15	2,7 M TL
120	3	5	4,1 M TL
65	1	30	1,6 M TL

Her örneğin doğru cevabı bilinir. **Gözetimli öğrenmede** kullanılır.

Etiketsiz veri

Aylık harcama	Ziyaret	Sepet
4.500 TL	12	375 TL
800 TL	2	400 TL
5.200 TL	15	347 TL

Sadece özellikler vardır, cevap sütunu yoktur. **Gözetimsiz öğrenmede** kullanılır.

Etiketleme maliyeti: Etiketleri çoğu zaman insanlar üretir. Bir röntgenin "tümör var / yok" etiketini bir radyolog koyar. Bu nedenle etiketli veri, etiketsiz veriye göre daha azdır ve daha pahalıdır.

ÖĞRENME TÜRLERİ

Makine öğrenmesinin türleri



GÖZETİMLİ ÖĞRENME

Sınıflandırma ve regresyon

Sınıflandırma

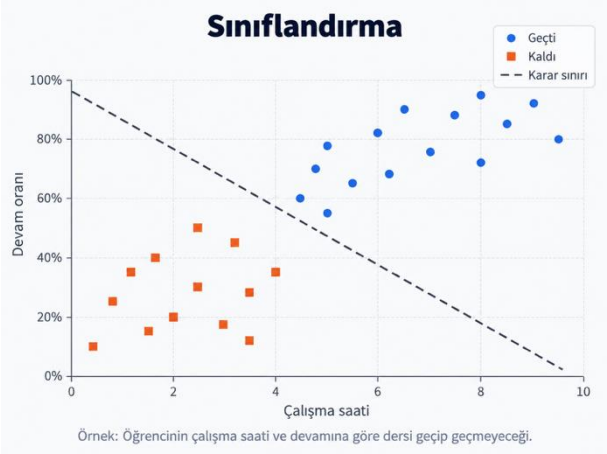
Çıktı bir **kategoridir**.

● Geçti

■ Kaldı

- - Karar sınırı

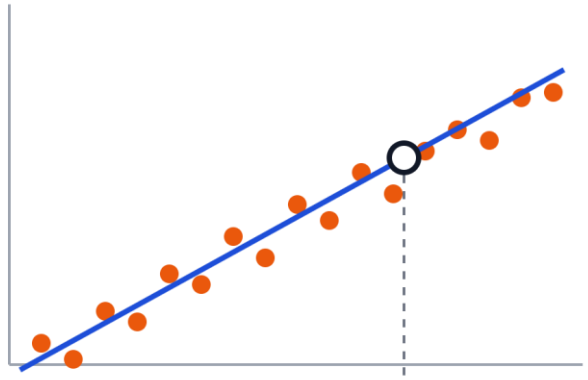
Yatay: çalışma saati
Dikey: devam oranı



Örnek: Öğrencinin çalışma saati ve devamına göre dersi geçip geçmeyeceği.

Regresyon

Çıktı bir **sayıdır**.



● Satılmış evler

— Model

○ Yeni ev tahmini

Yatay: metrekare
Dikey: fiyat

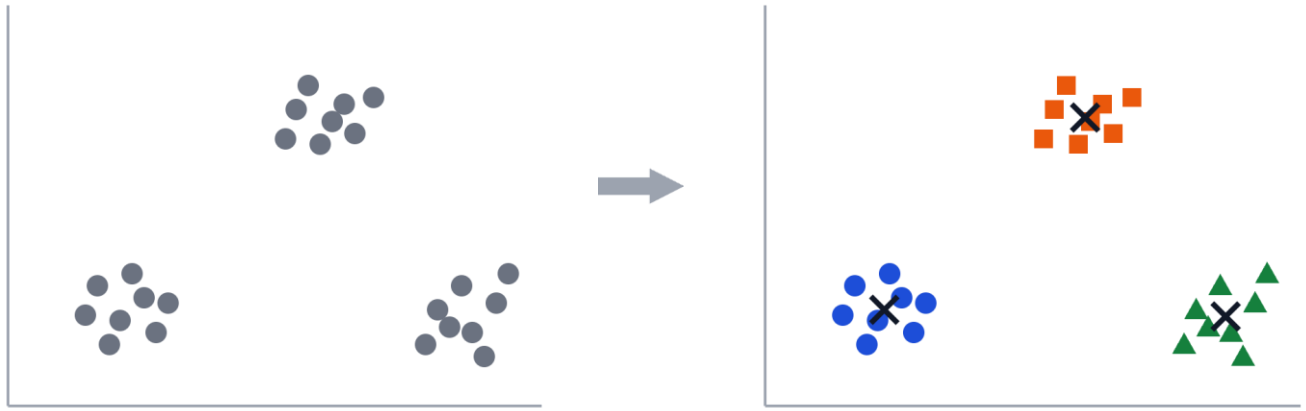
Örnek: Evin metrekaresine göre satış fiyatı.

GÖZETİMSİZ ÖĞRENME

Kümeleme: etiket olmadan gruplama

1. Modelin gördüğü veri

2. Modelin bulduğu 3 küme



K-Means

k merkez seçilir, her nokta en yakın merkeze atanır, merkezler grubun ortasına taşınır; bu adımlar tekrarlanır. × işaretleri merkezlerdir.

Boyut indirgeme

Çok sayıda özelliği az sayıya indirir. PCA yöntemi en bilinenidir.

Örnek: Yatay eksen aylık harcama, dikey eksen alışveriş sıklığı. Model müşterileri 3 gruba ayırır; gruplara "sık ve az harcayan" gibi anlamlı isimler vermek insanın işidir.

SÜREÇ

Bir makine öğrenmesi projesinin adımları

1

Problemi tanımla

Ne tahmin edilecek? Hangi veri gerekli?

2

Veriyi topla, tanı

Satır ve sütun sayısı, eksik değerler, grafikler

3

Veriyi hazırla

Eksik değer, kategorik kodlama, ölçekleme

4

Eğitim / test ayır

Örneğin %80 eğitim, %20 test

5

Modeli eğit

Algoritma seçilir, eğitim verisiyle öğrenir

6

Değerlendir

Test verisinde doğruluk, MAE, R^2

7

Kullan ve izle

Yeni verilerde tahmin, performans takibi

Sonuç yetersizse 2.–5. adımlara geri dönülür: daha fazla veri, farklı hazırlık ya da başka bir algoritma denenir.

SÜREÇ

Eğitim verisi ve test verisi

Iris veri seti: 150 çiçek



Model bu örneklerle öğrenir

Hem özellikler (X) hem doğru cevaplar (y) modele verilir.

Sınav

Eğitimde hiç kullanılmaz.

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)
```

Neden ayırıyoruz?

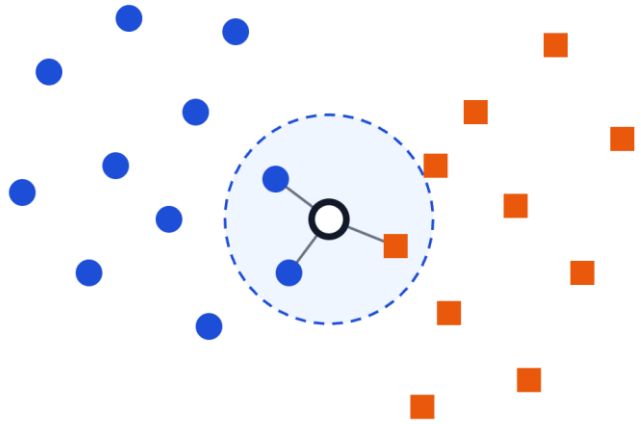
Eğitim verisindeki başarı ezberi de ölçebilir. Test verisindeki başarı, modelin daha önce görmediği verilerde nasıl çalışacağını gösterir.

Doğrulama verisi

Model ayarlarını seçerken eğitim verisinden ayrıca bir doğrulama (validation) kümesi ayrılır; test verisi en sona saklanır.

ALGORİTMALAR

K-En Yakın Komşu (KNN)



● versicolor ■ virginica ○ yeni çiçek

Yeni bir örneğin sınıfı, ona en çok benzeyen **k** eğitim örneğinin çoğunluk oyuyla belirlenir.

1. Yeni örnekle tüm eğitim örnekleri arasındaki uzaklığı hesapla.
2. En yakın k örneği seç (şekilde k = 3).
3. Bu komşuların çoğunluğu hangi sınıftaysa onu tahmin et.

Şekilde 2 mavi, 1 turuncu komşu var: tahmin **versicolor**.

k çok küçükse model tek tek örneklere fazla duyarlı olur; k çok büyükse ayrıntıları kaçırır.

ALGORİTMALAR

Karar ağacı



Nasıl öğrenir?

Veriyi en iyi ayıran evet/hayır sorusunu seçer, her dal için aynı işlemi tekrarlar.

Avantajı

Öğrenilen kurallar bir insan tarafından okunabilir.

Dikkat

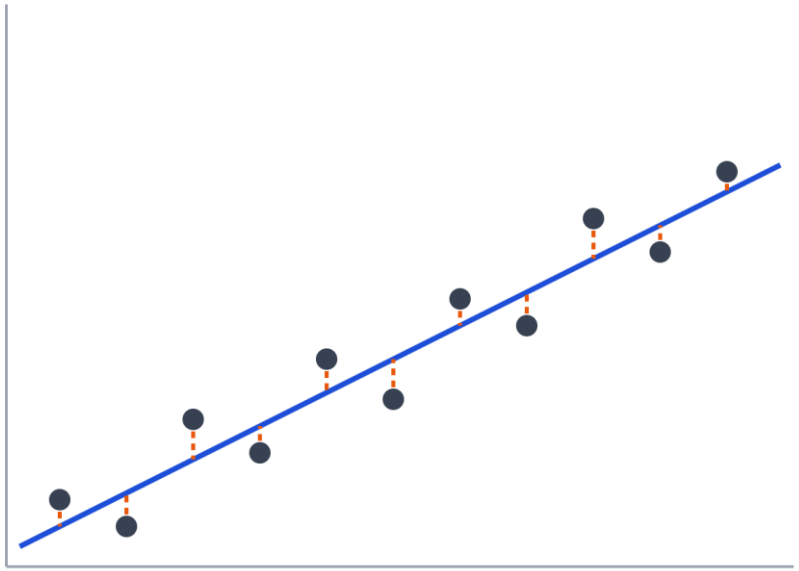
Çok derin bir ağaç eğitim verisini ezberler. Bu yüzden derinlik sınırlanır.

Rastgele orman

Yüzlerce ağacın tahminlerini birleştirir; genellikle tek ağaçtan daha iyidir.

ALGORİTMALAR

Doğrusal regresyon



● Gerçek ev — Model ¦ Hata · Yatay: metrekare, dikey: fiyat

```
fiyat = a × metrekare + b
```

a (eğim) ve **b** (sabit) modelin veriden öğrendiği **parametrelerdir**.

Model, turuncu çizgilerle gösterilen hataların karelerinin toplamını en küçük yapan a ve b değerlerini bulur.

Örnek değerler: a = 30.000 TL, b = 300.000 TL

100 m² için tahmin: 30.000 × 100 + 300.000 = **3.300.000 TL**

Birden fazla özellikte her özellik kendi katsayısını alır: a_1·metrekare + a_2·oda + a_3·yaş + b

DEĞERLENDİRME · SINIFLANDIRMA

Karmaşıklık matrisi ve doğruluk

Spam filtresi, 100 test e-postası

		Modelin tahmini: Spam	Modelin tahmini: Normal
Gerçek	spam	40 doğru pozitif	10 yanlış negatif
Gerçek	normal	5 yanlış pozitif	45 doğru negatif

Mavi köşegen: doğru tahminler · Turuncu: hatalar

Doğruluk (accuracy)

Tahminlerin yüzde kaçı doğru?

`(40 + 45) / 100 = %85`

Kesinlik (precision)

"Spam" denenlerin yüzde kaçı gerçekten spam?

`40 / (40 + 5) = %89`

Duyarlılık (recall)

Gerçek spamlerin yüzde kaçı yakalandı?

`40 / (40 + 10) = %80`

DEĞERLENDİRME · REGRESYON

Hata ölçütleri: MAE ve R²

4 test evi (bin TL)

Ev	Gerçek	Tahmin	Hata	|Hata|
A	3.000	2.800	+200	200
B	2.500	2.650	−150	150
C	4.200	4.000	+200	200
D	1.800	1.850	−50	50

MAE: ortalama mutlak hata

`(200 + 150 + 200 + 50) / 4 = 150 bin TL`

Tahminler ortalama 150 bin TL şaşıyor. Birimi etiketle aynıdır; 0'a yakın olması iyidir.

R²: belirlilik katsayısı

Model, her eve ortalama fiyatı (2.875) söyleyen basit bir tahmine göre ne kadar iyi?

`R² = 1 − (model hatası / ortalama tahmininin hatası) = 0,97`



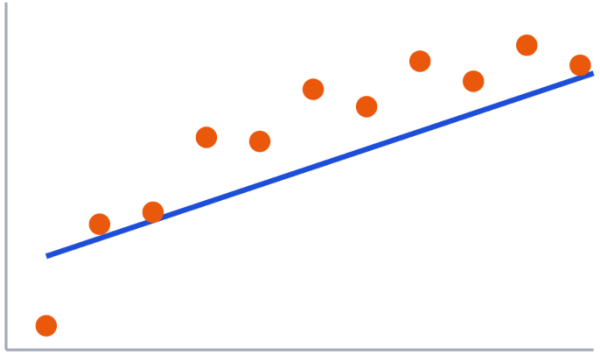
0: ortalamadan iyi değil

1: kusursuz

RMSE (kök ortalama kare hata): Hataların karesini alarak büyük hataları daha çok cezalandırır. Bu örnekte 162 bin TL.

İYİ MODEL KURMAK

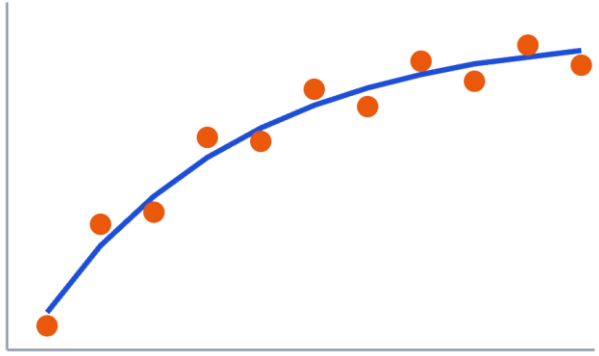
Yetersiz öğrenme ve aşırı öğrenme



Yetersiz öğrenme

Model çok basit; verideki eğriyi yakalayamıyor.

Eğitim hatası: **yüksek**
Test hatası: **yüksek**



Uygun model

Genel eğilimi yakalıyor, küçük sapmaları önemsemiyor.

Eğitim hatası: **düşük**
Test hatası: **düşük**



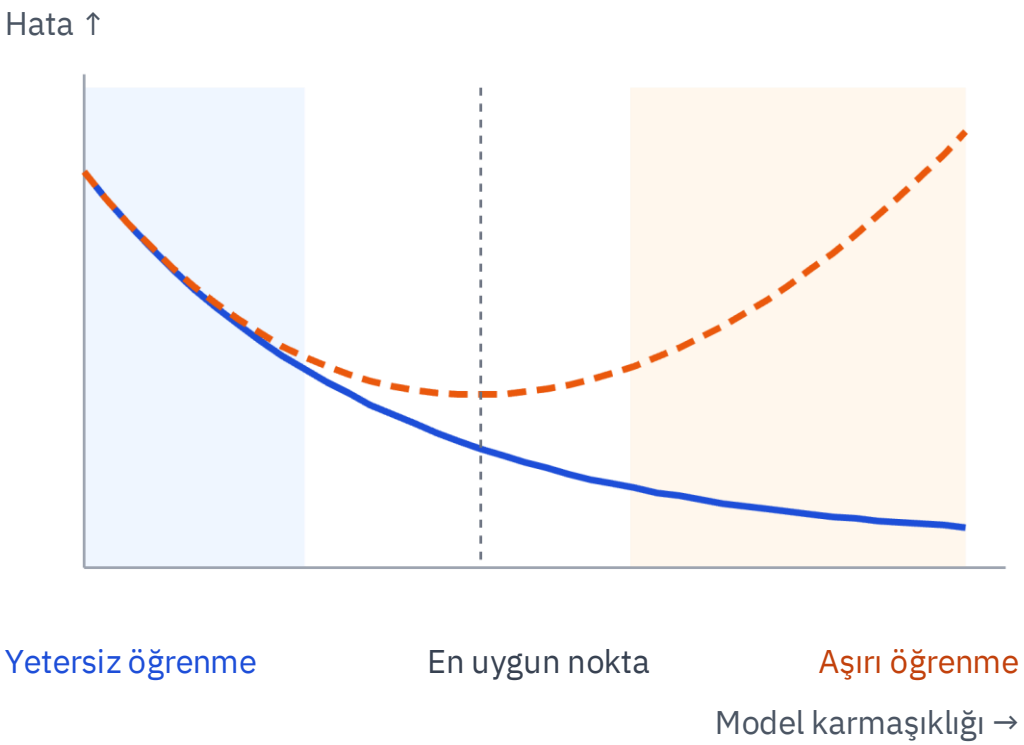
Aşırı öğrenme

Model her noktadan geçiyor; gürültüyü de ezberliyor.

Eğitim hatası: **çok düşük**
Test hatası: **yüksek**

İYİ MODEL KURMAK

Model karmaşıklığı ile hata arasındaki ilişki



—— Eğitim hatası

- - - Test hatası

Model karmaşıklaştıkça eğitim hatası sürekli düşer. Test hatası önce düşer, sonra yükselir.

Aşırı öğrenmeyi azaltmak için

- Daha fazla eğitim verisi toplamak
- Daha basit model seçmek (ör. ağaç derinliğini sınırlamak)
- Çapraz doğrulama ile ayar seçmek
- Gereksiz özellikleri çıkarmak

İYİ MODEL KURMAK

Veri hazırlama

Eksik değerler

Satır silinir, sütun atılır ya da değer doldurulur.

Yaş
22
boş
35
31

➡

Yaş
22
31
35
31

Boş hücre, sütunun medyanı (31) ile dolduruldu.

Kategorik veriler

Modeller sayılarla çalışır; yazılar sayıya çevrilir.

Şehir
İzmir
Ankara
İzmir
Van

➡

İzmir	Ankara	Van
1	0	0
0	1	0
1	0	0
0	0	1

One-hot kodlama: her değer için ayrı bir 0/1 sütunu.

Ölçekleme

Farklı birimlerdeki sayılar benzer aralığa getirilir.

Yaş	Maaş
25	20.000
40	45.000
60	90.000

➡

Yaş	Maaş
−1,2	−1,1
−0,1	−0,2
1,3	1,3

Ölçeklemeden önce uzaklık hesabında maaş, yaşı tamamen bastırır.

İYİ MODEL KURMAK

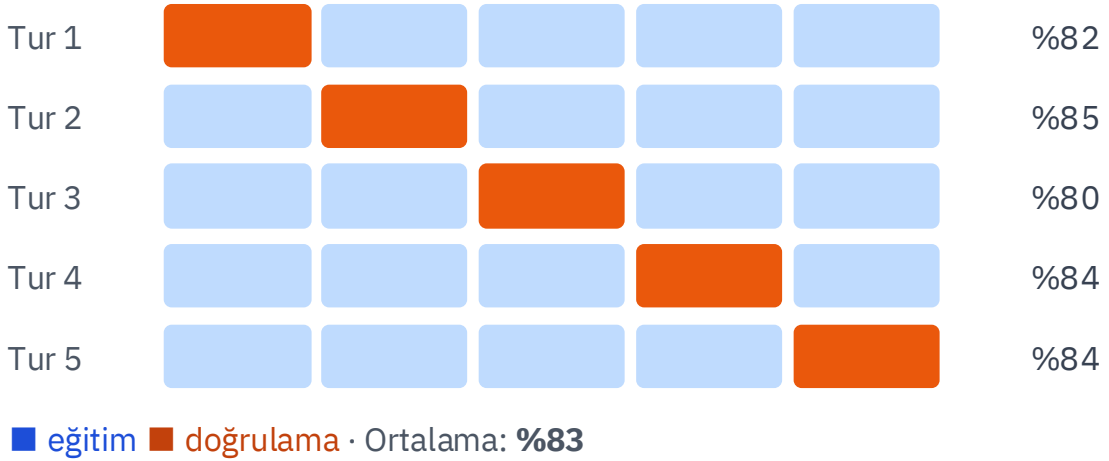
Hiperparametre ve çapraz doğrulama

Parametre ve hiperparametre

Model	Veriden öğrenilir	Biz seçeriz
Doğrusal regresyon	a ve b katsayıları	—
KNN	Eğitim örnekleri saklanır	k (komşu sayısı)
Karar ağacı	Sorular ve eşik değerleri	Maksimum derinlik
Rastgele orman	Her ağacın soruları	Ağaç sayısı

Hiperparametreler denenerek seçilir. Seçim test verisine bakılarak değil, çapraz doğrulama ile yapılır.

5 katlı çapraz doğrulama



SINIRLILIKLAR

Sınırlılıklar ve etik konular

Veri kalitesi

Model yalnızca eğitildiği veriden öğrenir. Hatalı, eksik ya da eski veriyle eğitilen model hatalı tahmin yapar. Örnek: 1990 yılı ev fiyatlarıyla bugünün fiyatı tahmin edilemez.

Yanlılık (bias)

Geçmiş verideki eşitsizlikler modele geçer. Örnek: Geçmiş işe alım kararlarıyla eğitilen bir model, belirli bir gruptan adayları sistematik olarak eleyebilir.

Açıklanabilirlik

Bazı modellerin neden o kararı verdiği anlaşılamaz. Kredi ya da sağlık gibi alanlarda kararın gerekçesi açıklanabilmelidir.

Gizlilik

Eğitim verisi kişisel bilgi içerebilir. Verinin toplanması ve kullanılması KVKK gibi düzenlemelere uygun olmalıdır.

ÖZET

Kavram sözlüğü

Türkçe	İngilizce	Kısa tanım
Model	model	Veriden öğrenilen, tahmin yapan yapı
Özellik	feature	Modelin girdisi olan ölçülebilir bilgi (X)
Etiket	label	Tahmin edilmek istenen doğru cevap (y)
Eğitim / test verisi	train / test	Öğrenmede ve değerlendirmede kullanılan ayrı parçalar
Sınıflandırma	classification	Kategori tahmini
Regresyon	regression	Sayı tahmini
Kümeleme	clustering	Etiketsiz veride benzer örnekleri gruplama
Karmaşıklık matrisi	confusion matrix	Gerçek ve tahmin edilen sınıfların çapraz tablosu
Doğruluk	accuracy	Doğru tahminlerin tüm tahminlere oranı
MAE / R^2	MAE / R-squared	Ortalama mutlak hata / açıklanan değişim oranı
Aşırı öğrenme	overfitting	Eğitim verisini ezberleyip yeni veride başarısız olma
Hiperparametre	hyperparameter	Eğitimden önce bizim seçtiğimiz model ayarı

UYGULAMA

Google Colab'de iki gözetimli öğrenme örneği

Uygulama 1 · Sınıflandırma

Iris çiçek türü

Veri bir **CSV dosyasından** okunur: 150 çiçek, 4 ölçüm, 3 tür.

- CSV okuma ve veriyi tanıma
- Eğitim / test ayırma
- KNN ve karar ağacı
- Doğruluk ve karmaşıklık matrisi

Uygulama 2 · Regresyon

Kaliforniya konut değerleri

Veri, scikit-learn kütüphanesindeki **hazır veri setinden** yüklenir: 20.640 bölge, 8 özellik.

- Doğrusal regresyon ve rastgele orman
- MAE, RMSE ve R^2
- Aşırı öğrenme grafiği
- Özelliklerin önemi

colab.research.google.com › Dosya › Not defteri yükle › .ipynb dosyasını seçin. Hücreleri sırayla Shift + Enter ile çalıştırın.